

The background of the slide features a stylized illustration of a multi-lane road that curves into the distance. Overlaid on the road are several sets of concentric circles, resembling radar or sonar waves emanating from a point in the distance, creating a sense of depth and motion.

# **DRIVE:**

## **Data-driven Road Intelligence for Vehicular Environments**

---

Mario Köpcke, Jonas Werner

15. April 2025

# Konzept & Design


## Kontext:

Verkehrsfluss in einer Stadt, bestehend aus einem Straßennetz mit Ampeln und Autos

## Ziel:

Verkehrsfluss optimieren, um Reisezeiten zu reduzieren


→ Ampeln befähigen, intelligente Entscheidungen zu treffen



# Konzept & Design - Agenten


## Autos (Simple Reflex Agent)

- *Performance Measure*: kürzeste Distanz durch Verkehrsnetz
- *Environment*: Verkehrsnetz bestehend aus Straßen, Kreuzungen mit Ampeln, Start- und Zielpunkten
- *Actuators*: Ziel suchen; kürzesten Pfad berechnen; fahren; anhalten
- *Sensors*: Kamera, GPS



## Ampeln (Utility-based Agent)


- *Performance Measure*: Menge an Autos, die pro Tick eine Ampel überqueren (durchschnittliche Wartezeiten der Autos)
- *Environment*: Verkehrsnetz bestehend aus Straßen, Kreuzungen mit Ampeln, Start- und Zielpunkten
- *Actuators*: Anpassung der Ampelschaltungen; Vorhersage, wie viele Autos bei Ampel ankommen werden
- *Sensors*: Kamera





# Umsetzung: Spieltheorie

- Autos als strategische Spieler:
  - Wählen individuell den kürzesten Pfad  
→ Zielkonflikte durch Überlastung bestimmter Routen
- Ampeln als eigenständige Akteure:
  - Optimieren lokal den Durchfluss  
→ Konkurrenz zwischen Kreuzungen entsteht
- Interessenskonflikte zwischen Autos und Ampeln:
  - Autos wollen minimale Wartezeit, Ampeln maximieren lokalen Verkehrsfluss



# Umsetzung: Optimierung

**Entscheidungsvariablen:** Öffnen oder Schließen von angrenzenden Straßen

$x_{lt} \in \{0, 1\}$  mit:  $l \in L$  : Auswahl der offenen Straße (lane) vom Typ  $l$  mit  $L = \{\text{angrenzende Straße}\}$ ,  
 $t \in T$  : Zeitpunkt vom Typ  $t$  mit  $T = [0; 6] \in \mathbb{N}$

**Restriktionen:**

- Jede Ampel kann nur exakt eine Straße gleichzeitig öffnen

$$\sum_{l \in L} x_{lt} = 1 \quad \forall t$$

- Jede Ampel kann nur alle 5 Ticks ihre Entscheidung ändern (“Cooldown”)

$$\sum_{t \in T} (x_{lt-1} - x_{lt})^2 \leq 1 \quad \forall l$$

**Zielfunktion:** Den Verkehrsfluss an jeder Ampel maximieren

$$f(x) = \sum_{t \in T} \sum_{l \in L}^{t \geq 1} x_{lt} \cdot q_{lt} \rightarrow \max! \quad q_{lt} : \text{Anzahl wartender Autos pro Straße } l \text{ zum Zeitpunkt } t$$

# Umsetzung: Machine Learning

**Ziel:**

Punktuelle Vorhersage der Autos an einer Ampel pro Straße

**Zweck:**


Input für die Optimierung der Ampelschaltung

**Bedingungen:**

- Daten müssen lokal verfügbar sein
- Modell sollte leichtgewichtig sein


**Verfahren:**

Supervised Learning - Regression




# Modellauswahl

R2-Score:



RMSE:



# XGB Regressor – Hyperparameter Optimierung

## Hyperparameter

colsample\_bytree = 1.0


gamma = 0

learning\_rate = 0.3

max\_depth = 8

min\_child\_weight = 5

n\_estimators = 300







# Live-Demo



# Analysen & Ergebnisse



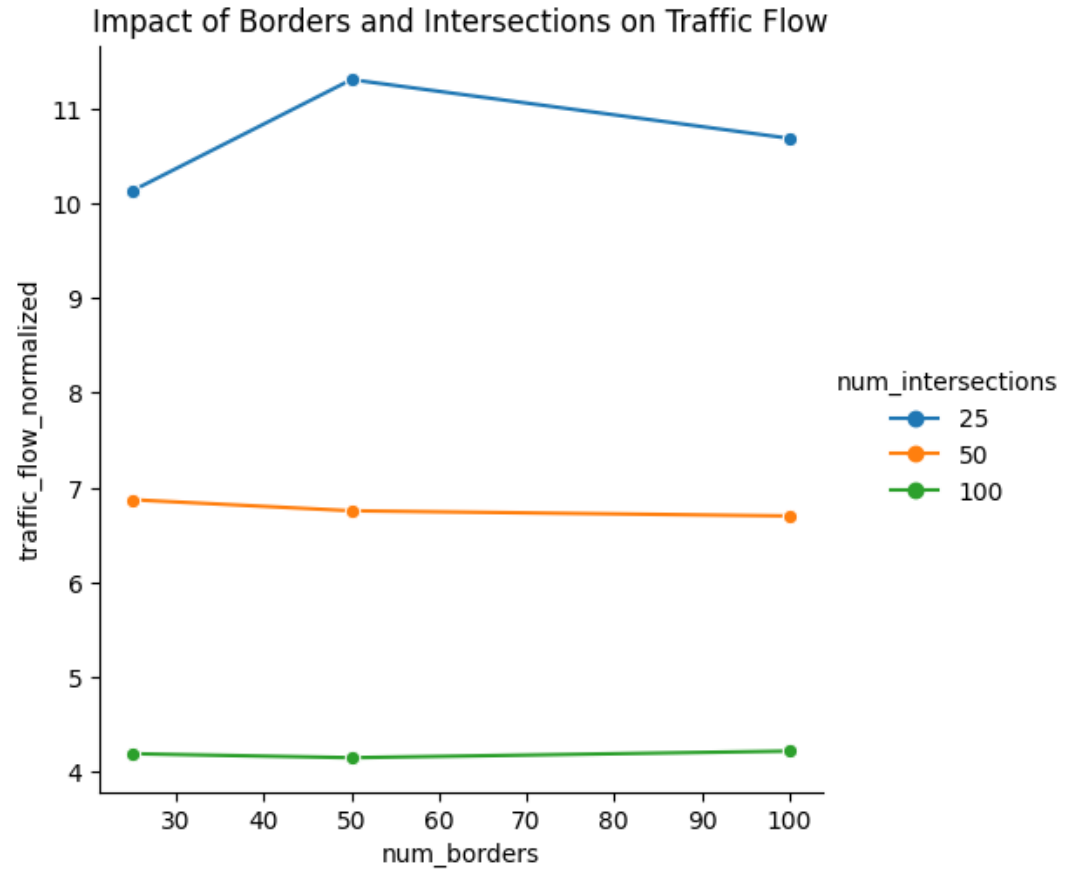
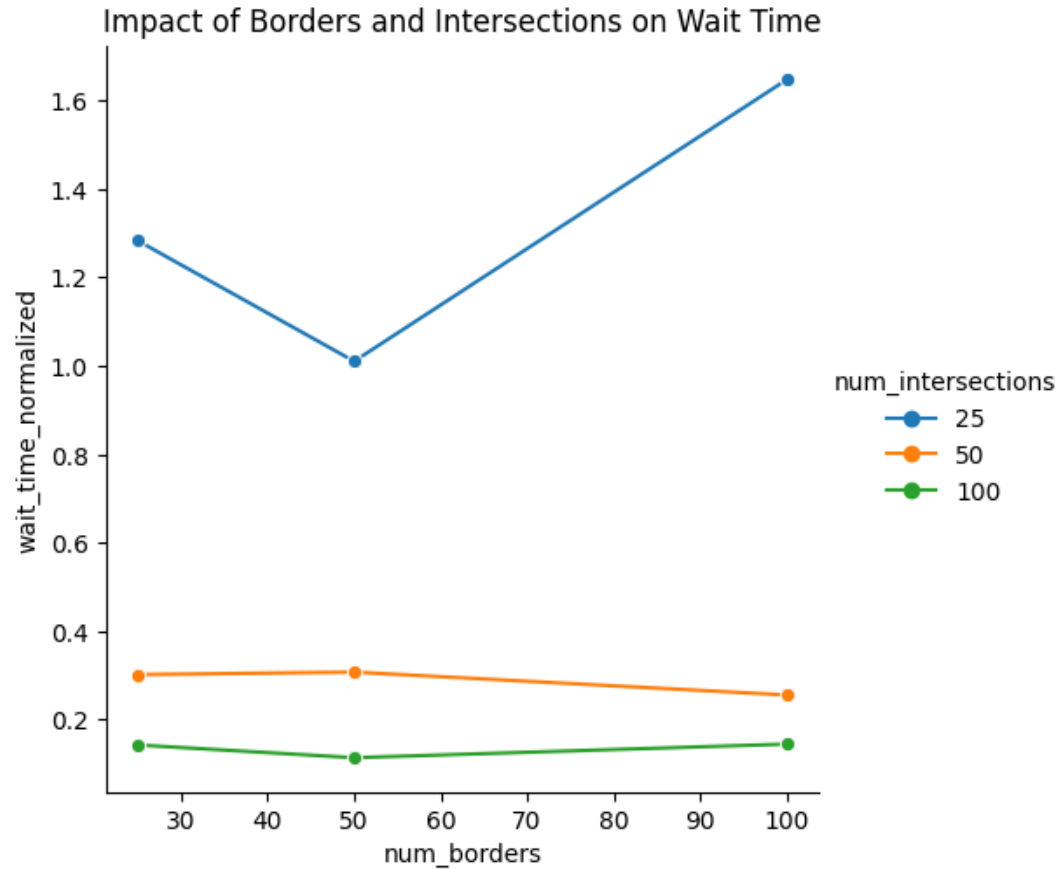
Auswirkung der Komplexität der Umgebung auf den Verkehrsfluss und die Wartezeiten



Auswirkung der Optimierungs-Modi auf den Verkehrsfluss und die Wartezeiten

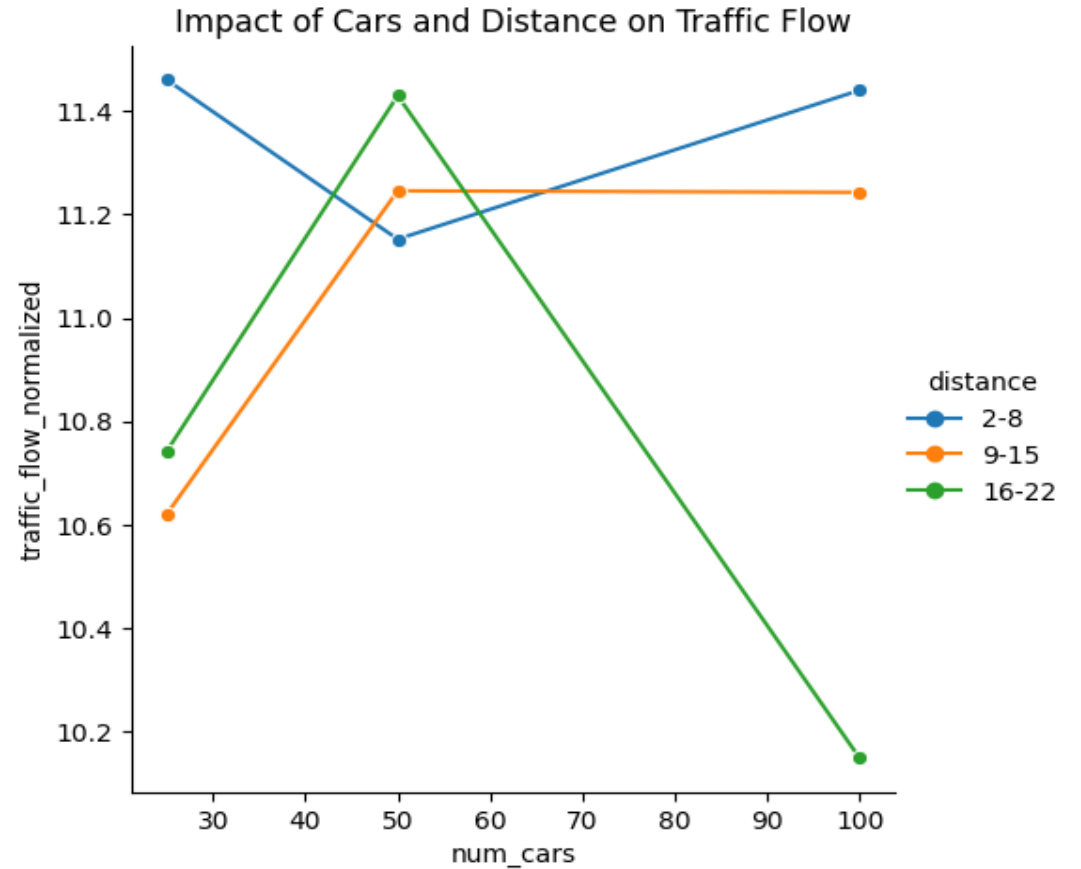
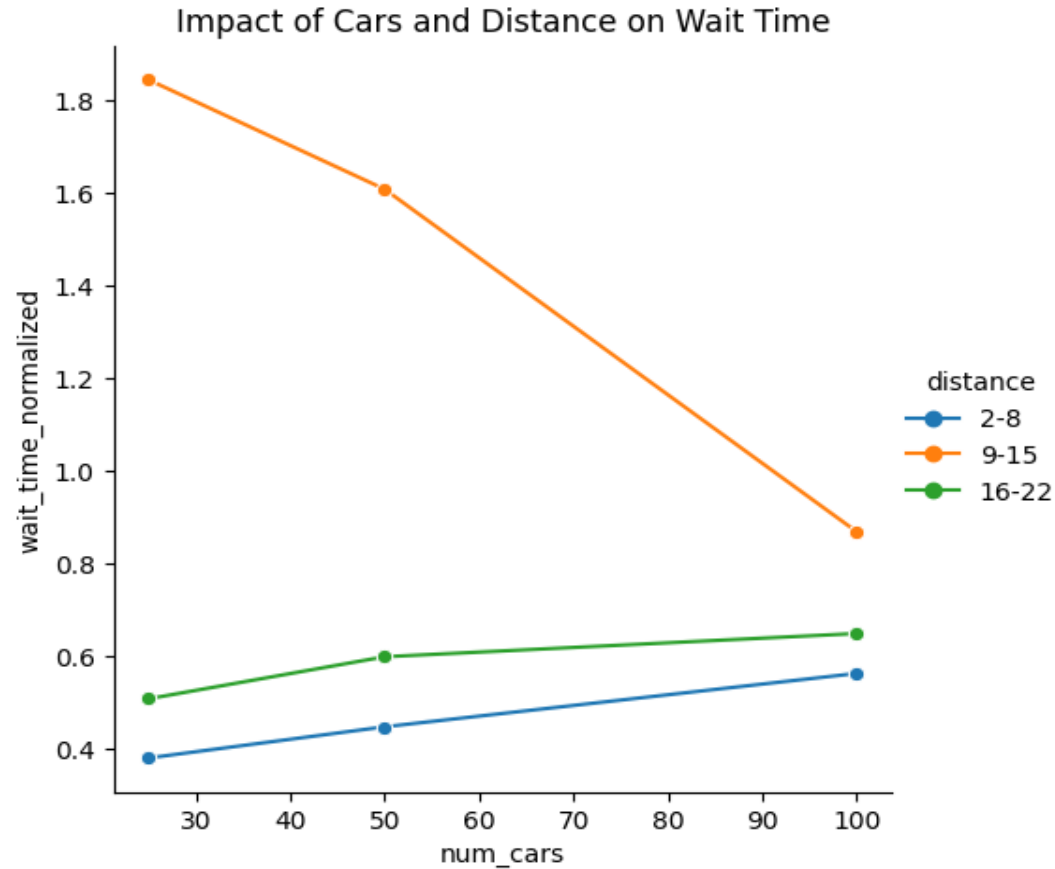
# Analysen & Ergebnisse

## Auswirkung der Komplexität der Umgebung





# Analysen & Ergebnisse

## Auswirkung der Komplexität der Umgebung



# Analysen & Ergebnisse

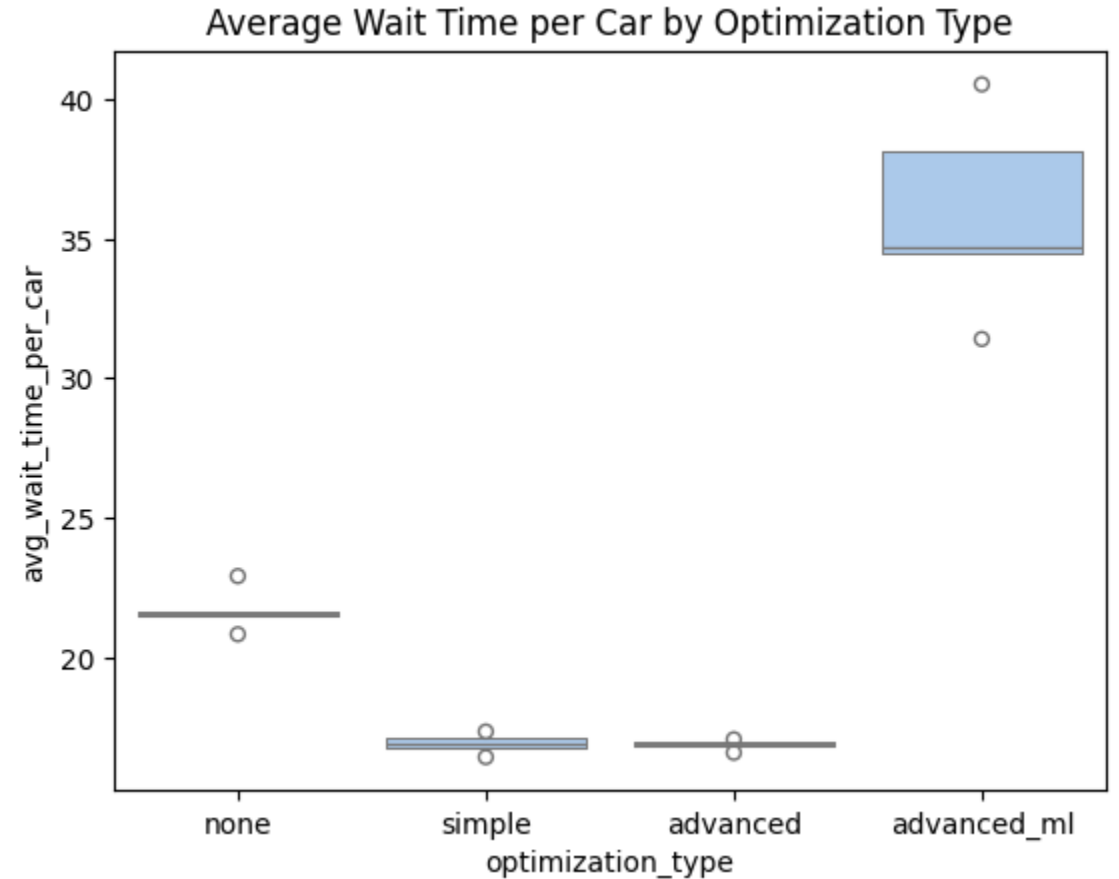

## Auswirkung der Optimierungs-Modi





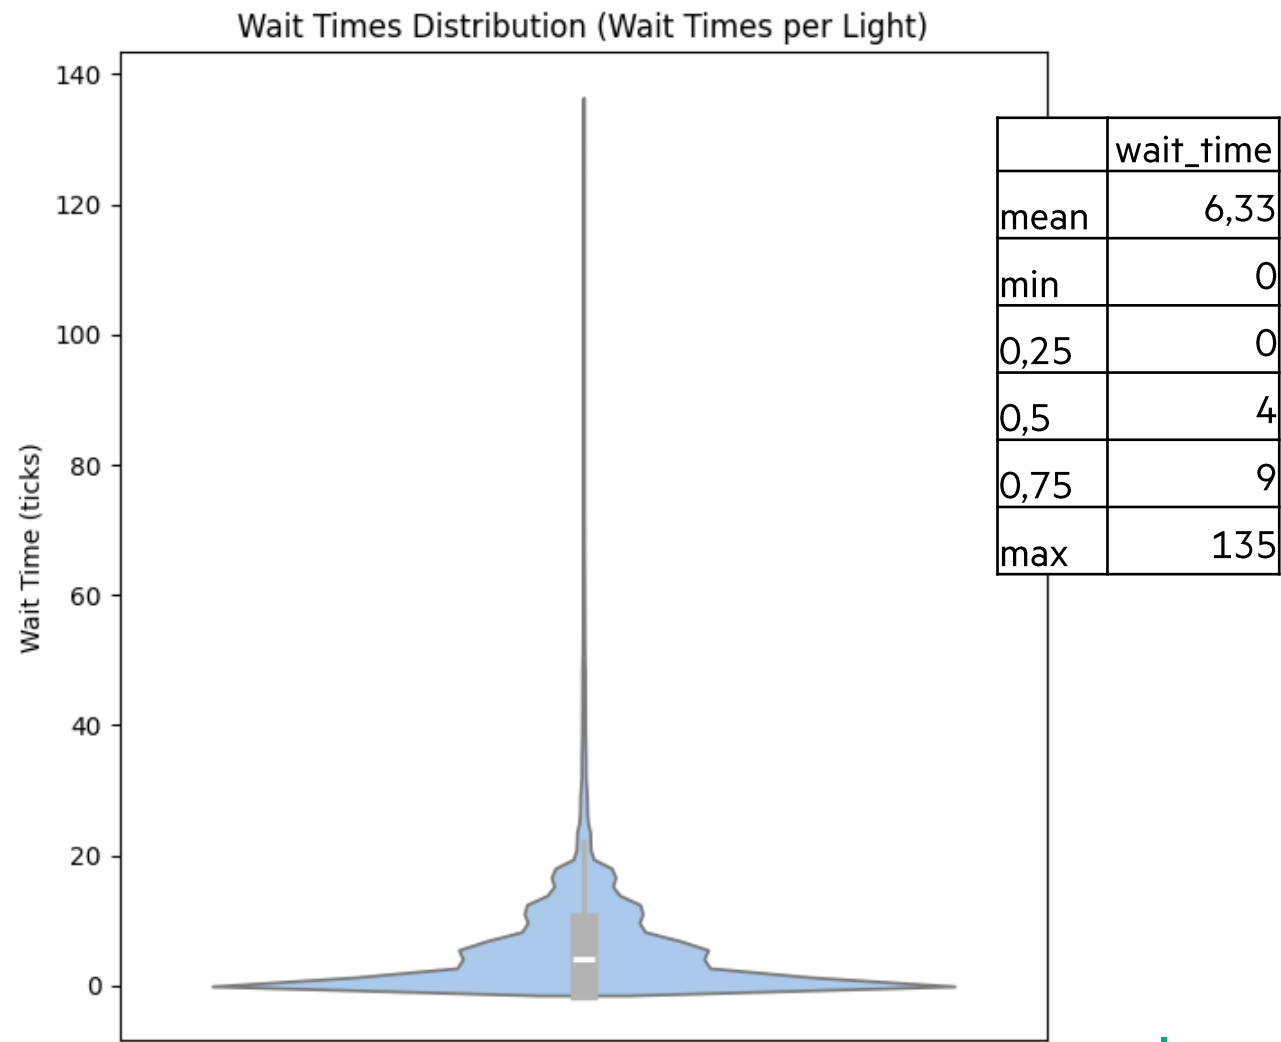
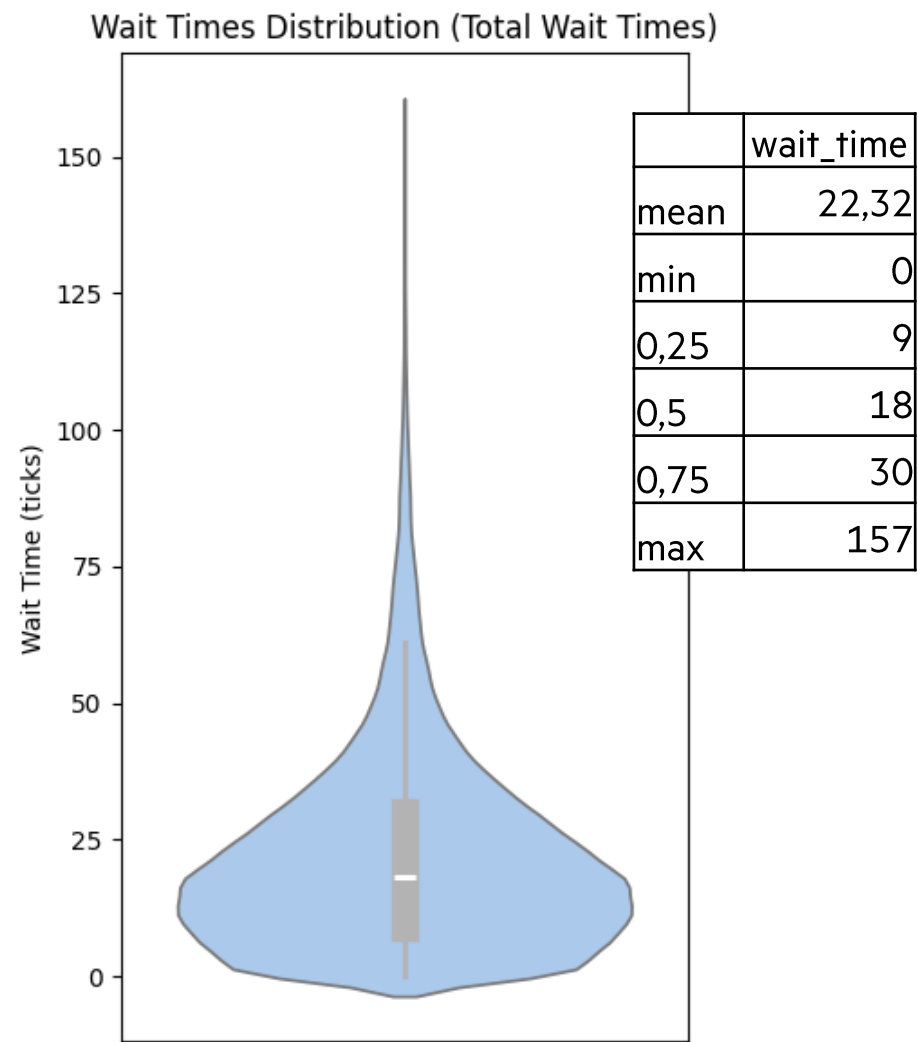
# Analysen & Ergebnisse

## Auswirkung der Optimierungs-Modi




# Analysen & Ergebnisse

## Auswirkung der Optimierungs-Modi



# Ausblick

- Realistische Ampelinteraktion: Autos stehen in Reihe, begrenzte Durchfahrt pro Zeitschritt
- Kontinuierliches Lernen im Machine Learning
- Einführung einer maximalen Wartezeit pro Auto
- Nutzung mehrerer Fahrspuren
- Adaptive Routenwahl basierend auf gelernten Wartezeiten
- Globale Optimierung durch Kommunikation zwischen Autos und Ampeln (zentrale Steuerung)



# Danke



Mario Köpcke, Jonas Werner



**DRIVE:**

**Data-driven Road Intelligence for Vehicular Environments**

---

Mario Köpcke, Jonas Werner

15. April 2025



# Anhang

---

# Projekt

[https://github.com/Jonas-wastaken/ias\\_project](https://github.com/Jonas-wastaken/ias_project)

# Aufgabenteilung

---

- Mesa Model: 50/50
- LightAgent: Mario
- CarAgent: Jonas
- Graphvisualisierung: Jonas
- Optimierung: Mario
- Machine Learning: Jonas
- Auswertung Analyse: Mario